Introduction of "Data Pre-Processing"

# About Data

徐华
清华大学 计算机系 智能技术与系统国家重点实验室
xuhua@tsinghua.edu.cn

1

Leading Question

# Data, Information and Knowledge?

2

## Leading Question

- Data : Number, Text, Figure, Audio, Video
- Information : Valuable Data
- Knowledge： non-trivial(非平凡的), implicit(隐含的), previously unknown(事先未知) and potentially useful(潜在用途) pattern or rules hidden in data

3

## About Data ( 1 )

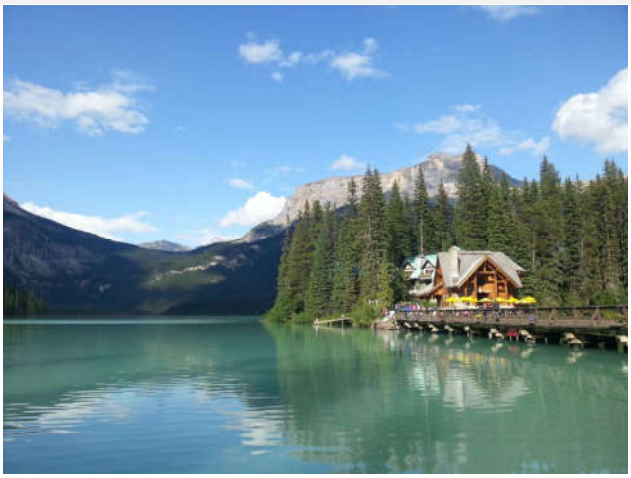

Emerald Lake in Banff National Park of Canada（2014）

4

## About Data ( 2 )


**2014 Beijing International Marathon**
**( Valuable Information )**

5

## About Data ( 3 )

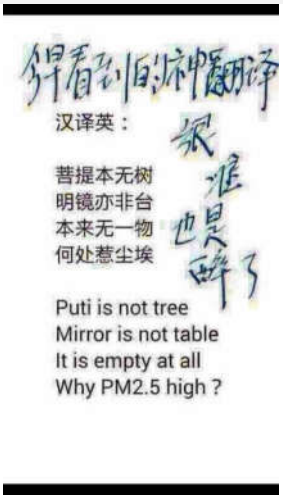


**Confused Information ( Dirty Data )**

6

## About Data ( 4 )


令人无语的分析与数据

7

## About Data ( 5 )

- **Multi-form and Multi-modal Data**


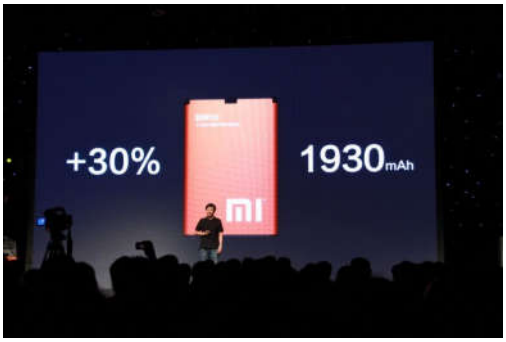


8

## About Data ( 6 )

- **Text from one student’s diary**

时间过得真快，一下就到半期考了，现在已经在开始紧张的复习了，我必须要开始努力了，因为我如果不努力，成绩就上不去，我成绩上不去就会被家长骂。我被家长骂，就会失去信心，失去信心就会读不好书，读不好书就不能毕业，不能毕业就会找不到好工作，找不到好工作就赚不了钱，赚不了钱就会没钱纳税，没钱纳税，国家就难发工资给老师，老师领不到工资就会没心情教学，没心情教学，就会影响我们祖国的未来，影响了祖国的未来，中国就难以腾飞，中华民族就会退化成野蛮的民族。中华民族成了野蛮的民族，美国就会怀疑我国有大规模杀伤性武器，我国有大规模杀伤性武器，美国就会向中国开战，第三次世界大战就会爆发，第三次世界大战爆发其中一方必定会实力不足，实力不足就会动用核武器，动用核武器就会破坏自然环境，自然环境被破坏，大气层就会破个大洞，大气层破个大洞地球温度就会上升，两极冰山就会融化，冰山融化，地球水位就会上升，地球水位上升，全人类就会被淹死。因为这关系到全人类的生命财产安全，所以我要在就剩下的几天里好好复习，考好成绩，不让悲剧发生。



## About Data ( 7 )

- **Focused on Image**

## About Data ( 8 )


11

## About Data ( 9 )


12

## About Data ( 10 )


13

## About Data ( 11 )


14

## About Data ( 12 )


15

## About Data ( 13 )


16

## About Data ( 14 )


17

## About Data ( 15 )


18

## About Data ( 16 )

当然，老外也模仿：

这次终于轮到别人抄我们。。。


抄的还是腾讯，我估计腾讯也没想到。。。

19

## About Data ( 17 )

细微的变化，实在有失水准


还有这个撞得天下皆知的。。。


车标貌似是重灾区。。。


20

## About Data ( 18 )


MDEC Logo　　中秋节 Logo


09大连海事大学校庆 Logo　　上海海洋大学校庆 Logo

争取把撞标撞向全世界


兰亚创意设计 Logo　　韩国丽水世博会中国馆 Logo

21

## About Data ( 19 )

GV车半年内
这个连颜色都不换一下


菲律宾银行MCC Logo　　武汉市城市一卡通 Logo

还挺像模像样的


2016里约热内卢奥运会 Logo　　众恒传播 Logo

22

## About Data ( 20 )


家电下乡？旋转45°试试


23

## About Data ( 21 )


这个就不妥自下结论了，自己琢磨吧！

OK吗？OK！


24

## About Data ( 22 )

仔细看还真有那么点血缘关系

将前者旋转180°试试?

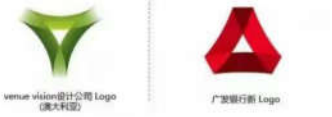

截取了Vivid Ways的肢体部分


25

## About Data ( 23 ) ——The emblem of the Tokyo Olympic Games


据《朝日新闻》报道，日前公布的2020年东京奥运会会徽被指与比利时一剧场的标志相似，该标志的设计师与剧场将以涉嫌侵犯知识产权为由向国际奥委会（IOC）提出申请，要求停止使用相关会徽。

26

## About Data ( 24 ) —— Similarity = Joke

八宝山人民公墓
BA BAO SHAN PEOPLE'S CEMETERY

V.S.

Lufthansa

27

## About Data ( 25 ) —— Similarity = Joke



29

## About Data ( 26 ) —— Similarity = Joke



30

## About Data ( 27 ) —— Similarity = Joke


31

## About Data ( 28 ) —— Deeply Impressive


32

## About Data ( 29 ) —— Deeply Impressive

NASA地球照片

风云四号卫星画面



## About Data ( 30 )

- Data Labeling

Dissolving

Brushing

Scrubbing

## About Data ( 31 )

- **Augmented Data**

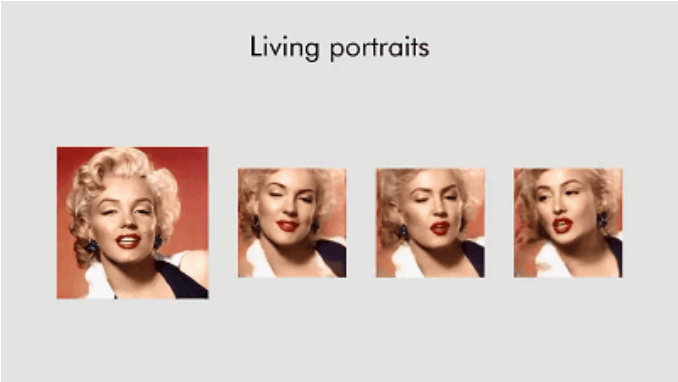


35

## Beginning from Basic and Abstract Numeric data

36

# Thanks !